Ficha de IA Responsable — AURA Care

Desafío Ciudad Aethera · Entregable 2 · Grupo 9 · Misiones M1, M5 y M6 · Prototipo con datos 100% sintéticos

1. Modelos y herramientas de IA

Herramienta	Proveedor	Propósito
Gemini 3.8 Flash (`gemini-3.8-flash`), API de Google AI Studio, nivel gratuito	Google	Redactar la respuesta al estudiante usando solo los servicios recuperados de D6.
Clasificador TF-IDF + regresión logística (scikit-learn)	Código abierto	Estimar la necesidad (motivo) cuando las reglas léxicas no coinciden; entrenado con D5.
Reglas deterministas (crisis, recuperación sobre D6, validador de salida)	Equipo	Seguridad y trazabilidad: no dependen del modelo generativo.
Google Colab	Google	Entorno de ejecución del notebook.

2. Datos utilizados

Solo el Data Pack sintético: D1, D2, D3 (score y métricas), D4 (análisis agregado), D5 (estructura de conversación y clasificador) y D6 (recuperación de servicios). No se usan datos reales ni datos externos sensibles; no se redistribuye el Data Pack. A Gemini solo se envían el mensaje de prueba y los datos de servicios ficticios de D6. El nivel gratuito de Google puede usar los prompts para mejorar sus productos: por eso no deben ingresarse datos personales reales.

3. Alcance y límites

Hace: orienta de forma preventiva, explica rutas de apoyo disponibles en D6 (servicio, horario, canal) y deriva a una persona cuando detecta crisis. **No hace:** no diagnostica, no interpreta síntomas, no sugiere tratamientos, no simula terapia y no decide por la persona. Apoya, no reemplaza, la atención profesional. El score preventivo es agregado, no individual ni clínico, y sus ponderaciones son reglas del equipo sin validación clínica.

4. Riesgos identificados y mitigaciones

Riesgo	Mitigación	Estado
Diagnóstico o lenguaje clínico	Instrucción al modelo + validador que bloquea términos clínicos y exige declarar que es una IA	Implementado
Servicios, horarios o requisitos inventados	Recuperación acotada a D6; el validador rechaza cualquier service_id inexistente; si falla, respuesta segura de plantilla	Implementado
Atribuir a un servicio especialidades que D6 no declara	Al modelo no se le entrega esa relación; solo puede citar tipo, horario, canal y distrito. El validador detecta la atribución y pide una corrección antes de usar la plantilla	Implementado
Crisis	Detector de reglas que corre antes del modelo y suspende la recomendación; entrega líneas de ayuda de Chile y Perú. Prueba de humo propia: 12/12 mensajes de crisis detectados, 0/12 falsos positivos (conjunto pequeño, no validado)	Implementado (léxico a ampliar)
Sesgo por país, etapa, género, migración o red de apoyo; sesgos intencionales del Data Pack	Auditar recomendaciones por segmento antes de cualquier piloto. Límite conocido: el clasificador aprendió de textos plantillados de D5 y puede generalizar mal a texto libre	Planificado
Privacidad	Solo datos sintéticos; el prototipo no almacena conversaciones	Implementado

5. Supervisión humana

En el prototipo, las derivaciones y respuestas de crisis siguen reglas definidas por el equipo. Para un piloto se propone: revisión semanal de rutas preventivas por orientadores, auditoría quincenal de calidad, sesgos y límites por el equipo técnico, y validación por profesionales de bienestar antes de exponer el agente a estudiantes. **Esa supervisión es una propuesta de diseño: no está implementada en el prototipo.** Las líneas de ayuda incluidas deben verificarse antes de cualquier uso real.

6. Transparencia e integridad en salud mental

El agente declara desde el primer mensaje que es una IA, explica por qué recomienda cada recurso y cita su fuente (service_id de D6). Usa lenguaje respetuoso y no estigmatizante, habla de señales y necesidades, no de trastornos, y recuerda que la decisión de pedir apoyo es de la persona.